APPRENTISSAGE DE POLITIQUES SÉCURITAIRES DANS DES ENVIRONNEMENTS AVEC DYNAMIQUES NON-DÉTERMINISTES*

RAPORT FINAL

Simon Nadeau
Département d'informatique et de génie logiciel
Université Laval
Québec, QC, Canada G1V0A6
simon.nadeau.12@ulaval.ca

Marco A. Vidalon Baldeon
Département d'informatique et de génie logiciel
Université Laval
Québec, QC, Canada G1V0A6
marco-antonio.vidalon-baldeon.1@ulaval.ca

May 1, 2026

1 Cas d'étude

Afin d'évaluer la capacité d'évitement des situations dangereuses en apprentissage par renforcement (RL), nous utilisons l'environnement non déterministe FrozenLake-v1 de la librairie Gymnasium [Towers et al., 2024]. L'agent, initialement en S, doit atteindre le but G en choisissant à chaque pas une action parmi {gauche, bas, droite, haut}. L'épisode se termine lorsqu'il atteint G ou tombe dans un trou (H). Le paramètre p contrôle le niveau de stochasticité : l'agent suit l'action choisie avec probabilité p, sinon il dévie vers une direction perpendiculaire avec probabilité $(1-p)/2$. La difficulté de l'environnement dépend du nombre et du positionnement des trous, ainsi que de la probabilité p. Nous avons choisi une valeur élevée de $p = 0.9$, afin de permettre l'exploitation de trajectoires risquées dans des environnements complexes tout en conservant une probabilité raisonnable d'atteindre le but.

La Figure 1 présente les cartes de risque associées aux trois cas étudiés (voir Section 3.3 pour la définition du risque). Dans le premier cas, nous utilisons l'environnement 8×8 par défaut de FrozenLake-v1 afin de comparer nos résultats à ceux de la littérature. Cet environnement comporte 10 trous (15.6 % des états) et admet un chemin central plus risqué vers le but, longeant davantage de trous, ainsi qu'un chemin de même longueur mais plus sécuritaire, via la partie supérieure droite. Le deuxième cas étudie le compromis entre longueur de trajectoire et risque. Nous avons conçu une grille 10×10 avec 12 trous, comprenant un trajet court mais très risqué, et des trajets plus longs de risque décroissant. La réduction du risque implique donc nécessairement un détour. Enfin, le troisième cas évalue la robustesse des stratégies RL dans des environnements plus complexes. Dix grilles 16×16 contenant 15% de trous ont été générées aléatoirement (une par répétition), avec un départ en (0,0) et un but en (15,15). Les stratégies RL ont été évaluées sur les mêmes environnements afin d'assurer une comparaison équitable. Nous supposons qu'il n'existe aucun lien entre les différents états: un état est représenté par le numéro de la case, utilisé directement pour les méthodes tabulaires et transformé en vecteur *one-hot* pour les méthodes basées sur l'approximation de fonction.

La durée maximale d'un épisode est fixée à 60 pas de temps pour l'environnement 8x8, au-delà desquels l'épisode est tronqué. Pour les environnements 10x10 et 16x16, plus complexes et nécessitant davantage d'exploration, le nombre de pas de temps maximum est augmenté à 100, au delà duquel l'agent serait porté à chuter afin d'éviter d'accumuler davantage de récompenses négatives (-0.01 par pas de temps).

Les récompenses associées à chaque cas sont définies en fonction de l'environnement considéré. Pour l'environnement 8×8, nous suivons la configuration proposée par Zhu et al. [2025] : une récompense de $r_G = 1$ pour l'atteinte du but, $r_H = -0.1$ pour une chute dans un trou, et $r_I = -0.01$ pour le passage sur une case de glace. Ces récompenses permettent de mettre en évidence le compromis entre la longueur des trajectoires et la prise de risque. Une pénalité r_H trop élevée empêche l'exploration de zones risquées, tandis qu'une pénalité insuffisante peut inciter l'agent à se suicider en début d'apprentissage afin d'éviter l'accumulation de récompenses r_I négatives trop importantes avant d'atteindre le but. Ainsi, pour les environnements 10×10 et 16×16, r_H est augmentée à -0.5 et -1, respectivement, afin de tenir compte des trajectoires plus longues nécessaires pour atteindre le but.

*Code disponible sur : https://github.com/sinadeau/SafeRL-IFT-7201

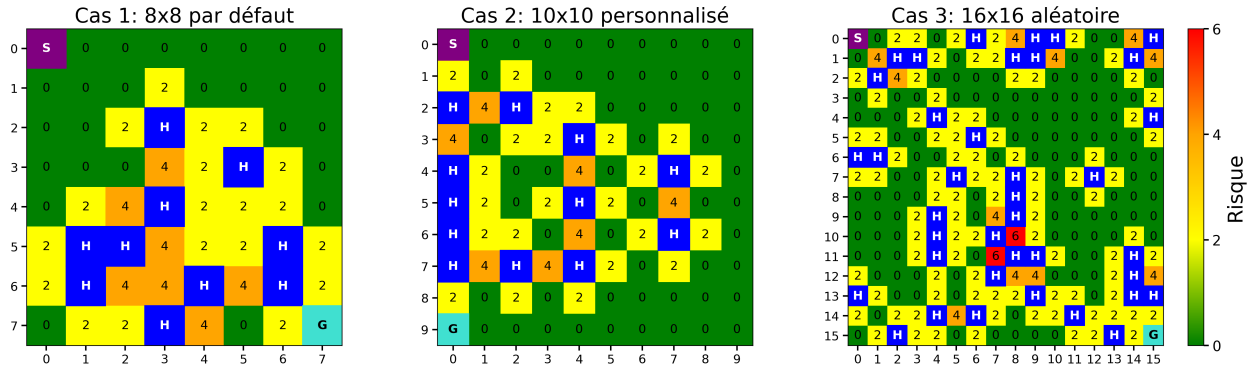


Figure 1: Cartes de risque des trois cas d'études. S = état de départ; G = but; H = trou. Les cellules restantes indiquent le niveau de risque correspondant au nombre de trous adjacents à la cellule courante, multiplié par 2 (voir Section 3.3). Le troisième cas montre un des 10 environnements 16x16 générés aléatoirement.

La formulation CMDP (*Constrained Markov Decision Process*) utilisée dans les méthodes de RL *sécuritaire* introduit une distinction fondamentale entre les notions de récompense et de coût [Ray et al., 2019]. Dans une approche MDP standard, l'attribution d'une récompense négative pour une action indésirable confond deux objectifs distincts : la maximisation de la performance et le respect des contraintes de sécurité. La formulation CMDP dissocie explicitement ces deux dimensions en attribuant à chaque action à la fois une récompense et un coût. Ainsi, lorsque l'agent tombe dans un trou, il encourt un coût de $c_H = 1$ et une récompense de $r_H = 0$ dans les trois environnements étudiés. Pour les autres états (but et glace), le coût est nul et les récompenses sont identiques à celles décrites précédemment. Le seuil de tolérance aux erreurs (d) dans un environnement donné correspond alors au taux de chute maximal que la politique doit respecter durant l'entraînement, tout en maximisant le rendement attendu. Dans l'environnement 8×8, un agent doit passer à côté de deux trous pour atteindre le but via le chemin le plus sécuritaire. Nous fixons donc d à la probabilité de chute correspondante ($d = 1 - 0.95^2 = 0.0975$). Pour l'environnement 10×10, nous fixons un seuil plus strict de $d = 0.05$ afin de favoriser les chemins plus longs et sécuritaires vers le but. Enfin, pour les environnements 16×16, plus complexes et variés, nous retenons un seuil moins contraignant de $d = 0.25$.

2 Stratégies considérées

2.1 Stratégies baselines

L'algorithme Q-learning est une méthode de contrôle par différences temporelles (TD) [Watkins, 1989]. Il estime une fonction de valeur d'action $q(s, a)$, représentant l'espérance de la somme des récompenses actualisées obtenues en exécutant l'action a depuis l'état s, puis en suivant la politique *greedy*. La nature *off-policy* de Q-learning réside dans le fait que la mise à jour de $q(s, a)$ utilise systématiquement la valeur de la meilleure action dans l'état suivant, indépendamment de l'action réellement choisie par la politique de comportement, typiquement une politique ϵ-greedy. La politique cible apprise est ainsi toujours la politique *greedy*. Étant donné que les espaces d'états et d'actions des environnements considérés dans ce projet sont discrets et de taille modérée, la table q peut être représentée de manière exacte, sans approximation de fonction. Q-learning constitue un *baseline* naturel dans ce projet : il s'agit d'un algorithme simple, bien compris et bénéficiant de garanties de convergence vers la politique optimale [Watkins, 1989]. Son caractère *off-policy* peut induire une prise de risque plus agressive : la politique cible peut apprendre des trajectoires plus risquées que celles effectivement suivies par la politique de comportement. Cela pourrait toutefois constituer un désavantage en RL sécuritaire, où l'objectif est de minimiser les chutes pendant l'apprentissage.

L'approche *Proximal Policy Optimization* (PPO) est largement utilisée en RL comme *baseline* en raison de ses bonnes performances sur de nombreux environnements [Schulman et al., 2017]. PPO s'inscrit dans la famille des méthodes acteur-critique (A2C) : elle apprend directement une politique par ascension de gradient stochastique à partir d'une cible TD, mais en utilisant une fonction objectif modifiée afin de limiter l'amplitude des mises à jour. Plus précisément, à chaque mise à jour, le ratio d'échantillonnage préférentiel (ρ_t) entre la nouvelle et l'ancienne politique est contraint à rester dans l'intervalle $[1 - \epsilon, 1 + \epsilon]$ via un mécanisme de *clipping* ($\epsilon > 0$). Il a été montré empiriquement que PPO offre un apprentissage plus stable et moins sensible aux hyperparamètres que A2C [Fuente and Guerra, 2024]. De plus, les mises à jour limitées permettent d'éviter des variations abruptes de la politique, susceptibles de conduire à des régions de faible récompense dans la surface d'optimisation [Sullivan et al., 2022]. Nous faisons l'hypothèse que PPO

pourrait être plus sécuritaire que Q-learning lors de l'entraînement : (1) l'approche *on-policy* incite la politique apprise à éviter les situations dangereuses pour maximiser les récompenses ; (2) l'absence de mises à jour brusques pourrait favoriser un comportement plus prudent en limitant la prise de risque lors de l'exploration.

PPO utilise en entrée des réseaux acteur et critique une représentation des états sous forme de vecteur *one-hot*. Dans ce cadre, l'approximation de fonction n'exploite aucune structure spatiale. Elle repose sur un partage de paramètres entre paires état-action, ce qui peut introduire un biais et mener à des estimations imparfaites des valeurs état-action. En revanche, Q-learning représente explicitement chaque paire état-action, éliminant ainsi toute erreur d'approximation. Sous des conditions standards d'apprentissage (exploration suffisante et taux d'apprentissage approprié), la convergence vers la solution optimale est garantie lorsque l'espace d'états est discret et de taille modérée, comme c'est le cas ici.

2.2 Stratégies sécuritaires

Dans un CMDP, nous cherchons à entraîner un agent RL qui maximise la récompense tout en contraignant l'accumulation d'un signal de coût (ici, le taux de chute) à rester sous un seuil prédéfini d. Formellement, une politique optimale en apprentissage par renforcement sous contraintes est définie par : $\pi^* = \arg\max_{\pi \in \Pi_C} J_r(\pi)$, où $J_r(\pi)$ désigne le retour cumulé actualisé attendu associé aux récompenses. L'ensemble des politiques admissibles est défini par $\Pi_C = \{\pi : J_C(\pi) \leq d\}$, où $J_C(\pi)$ correspond au retour de coût cumulé actualisé attendu.

Pour résoudre les problèmes d'optimisation sous contraintes, les méthodes primal-duales exploitent la dualité lagrangienne afin de reformuler le problème en un objectif non contraint, en y ajoutant un terme de pénalité pondéré par un multiplicateur de Lagrange (λ). Toutefois, les itérations intermédiaires violent souvent les contraintes en raison d'oscillations inhérentes à la dynamique d'apprentissage et au fait que λ n'est pas optimal [Spoor et al., 2025]. Les méthodes PID proposent des règles de mise à jour automatique de λ [Stooke et al., 2020], en ajoutant les termes *proportionnel* et *dérivatif* au contrôle *intégral* classique. Elles réduisent ainsi les oscillations de coût et améliorent le respect des contraintes tout en maintenant des récompenses cumulatives élevées. Néanmoins, leur utilisation en pratique reste délicate en raison de leur sensibilité aux trois hyperparamètres contrôlant la mise à jour de λ.

P3O (*Penalized Proximal Policy Optimization*) [Zhang et al., 2022] repose sur une optimisation du premier ordre pleinement compatible avec PPO. P3O reformule le problème contraint en un objectif non contraint en remplaçant la contrainte par une pénalité exacte fondée sur l'opérateur ReLU : $L_{P3O}(\theta) = L_R^{CLIP}(\theta) + \kappa \max(0,\, L_{C_i}^{CLIP}(\theta))$, où $L_R^{CLIP}(\theta)$ est la perte PPO *clipée* pour la récompense, $L_{C_i}^{CLIP}(\theta)$ son analogue pour la contrainte de coût i, θ les paramètres de l'acteur et κ un coefficient de pénalisation. Le mécanisme de *clipping* de PPO est étendu aux coûts:

$$\mathcal{L}_{C_i}^{\text{CLIP}}(\theta) = \mathbb{E}\left[\max\left(\rho_t \hat{A}_{C_i}, \text{clip}(\rho_t,\, 1-\epsilon,\, 1+\epsilon)\hat{A}_{C_i}\right) + (1-\gamma)\left(J_{C_i} - d_i\right)\right]$$

Où ρ_t et ϵ sont tel que définis pour PPO, $\hat{A}_{C_i}$ est l'avantage de coût, γ est le taux d'actualisation, et J_{C_i} et d_i sont définis précédemment. Ainsi, la pénalité est nulle lorsque la contrainte est satisfaite et croît proportionnellement au degré de violation, assurant une transition naturelle entre maximisation de la récompense et respect des contraintes.

La méthode PPO-Shield [le Court et al., 2025] adopte une approche différente : plutôt que de modifier la fonction objectif, elle construit un *bouclier* (un MDP de sécurité augmenté) qui restreint les actions disponibles de sorte qu'aucune politique apprise ne puisse violer la contrainte de sécurité. Ce bouclier est dérivé d'une borne supérieure inductive sur la probabilité minimale d'atteindre un état dangereux, obtenue par itération de valeurs avec garanties formelles. Chaque état augmenté associe à l'état original un niveau de sécurité représentant le budget de risque résiduel, contraignant les actions disponibles pour ne jamais le dépasser. La méthode offre des garanties formelles de sécurité et d'optimalité, et reste compatible avec tout algorithme de RL standard une fois le bouclier construit. Sa principale limitation est qu'elle requiert la connaissance des dynamiques de sécurité nécessaires à l'estimation du risque.

P3O a été retenu pour l'implémentation, car il offre des performances supérieures aux méthodes PID dans plusieurs environnements stochastiques similaires aux nôtres (p. ex. Point Goal et Car Goal de Safety Gym [Ray et al., 2019]) en termes de respect des contraintes et de récompenses cumulatives [Dai et al., 2023]. De plus, la méthode s'implémente aisément en ajoutant un terme de pénalité à PPO et ne nécessite que l'ajustement d'un seul hyperparamètre (κ).

3 Méthodologie expérimentale

3.1 Paramètres expérimentaux

Chaque stratégie est entraînée sur chacun des trois cas d'étude. Afin d'obtenir des intervalles de confiance sur les métriques de performance, toutes les expériences sont répétées $N = 10$ fois en utilisant une graine aléatoire différente. Chaque répétition est limitée à 150 000 épisodes. Nous comparons les stratégies de manière équitable en fonction du nombre d'épisodes plutôt que du nombre de pas de temps, afin de tenir compte des trajectoires de longueurs différentes.

3.2 Implémentation des algorithmes et hyperparamètres

L'implémentation de Q-learning est adaptée à partir d'un tutoriel disponible sur le site de Gymnasium . Le taux d'apprentissage initial est fixé à $\alpha_0 = 1$ et le facteur d'actualisation à $\gamma = 0.99$. La politique de comportement est ϵ-greedy, avec $\epsilon_0 = 1$ en début d'entraînement, favorisant ainsi une grande exploration de l'espace d'états. Les paramètres α et ϵ décroissent exponentiellement selon un facteur $\lambda = 0.9995$ par épisode, jusqu'à une valeur minimale $\epsilon_{\min} = 0.001$, ce qui favorise progressivement la convergence vers une politique optimale.

L'implémentation de PPO est réalisée à l'aide de la librairie Stable-Baselines3 [Raffin et al., 2021], avec les hyperparamètres par défaut, à l'exception de l'architecture du réseau de neurones. Nous avons réduit la taille des réseaux acteur et critique de récompense, chacun avec deux couches cachées de 16 neurones et des fonctions d'activation ReLU. Les espaces d'états et d'actions discrets et de taille modérés justifient cette architecture légère, qui permet de limiter le risque d'un apprentissage instable et bruité dû à la surparamétrisation, tout en restant suffisamment expressive pour approximer finement les fonctions de valeur d'état et de la politique.

Nous avons implémenté P3O à partir de l'architecture Stable-Baselines3, en s'inspirant de l'implémentation de la librairie Omnisafe [Ji et al., 2024]. Concrètement, nous avons ajouté un réseau critique de coût, indépendant et de même taille que les réseaux PPO décrits précédemment, qui estime la valeur espérée du coût cumulatif $\hat{V}_c(s)$. Ce critique est mis à jour séparément via un optimiseur dédié, en minimisant l'erreur quadratique moyenne entre les retours de coût, calculés à partir d'avantages de coût ($\hat{A}_c$) obtenus par GAE [Schulman et al., 2016], et $\hat{V}_c(s)$. Le taux d'actualisation pour les coûts est le même que pour les récompenses. En suivant l'implémentation d'Omnisafe, la perte de coût pour l'acteur est définie comme $\mathcal{L}_C = \kappa \cdot \max(0,\, \rho_t \hat{A}_c + \bar{c} - d)$, où $\bar{c}$ correspond au coût moyen par épisode, d est la limite de coût et ρ_t est le ratio d'échantillonnage préférentiel tel que défini pour PPO. Contrairement à l'article original [Zhang et al., 2022], $\mathcal{L}_C$ n'utilise pas de *clipping* sur ρ_t. Les avantages $\hat{A}_c$ sont normalisés afin d'utiliser une valeur de κ constante [Zhang et al., 2022]. La mise à jour de l'acteur et du critique de récompense se fait simultanément via une perte pondérée telle qu'implémentée dans Stable-Baselines3, à laquelle nous ajoutons $\mathcal{L}_C$:

$$\mathcal{L}_{P3O} = \mathcal{L}_R + \alpha \mathcal{L}_{\text{entropy}} + \mathcal{L}_C + \beta\, \mathcal{L}_{V_R}$$

Où $\mathcal{L}_R$ et $\mathcal{L}_C$ sont les pertes de politique associées respectivement au retour de récompense (*clipé*) et au coût attendu (*non clipé*). $\mathcal{L}_{\text{entropy}}$ est le terme de régularisation d'entropie, qui favorise l'exploration en pénalisant les politiques trop déterministes. $\mathcal{L}_{V_R}$ est la perte de la fonction de valeur, correspondant à l'erreur quadratique moyenne entre les valeurs de récompense prédites et les retours actualisés. Les mêmes valeurs par défaut ($\beta = 0.5$ et $\alpha = 0$) que pour PPO sont utilisées, sauf indication contraire. Une recherche d'hyperparamètres a été effectuée pour déterminer les valeurs de κ, avec les valeurs montrées à la Figure 3 (Annexe A). Toutes les expériences ont été réalisées sur CPU en Python 3.12.

3.3 Indicateurs de performance

Nous suivons quatre métriques pour analyser le compromis entre la longueur des trajectoires et l'évitement des situations dangereuses pendant l'apprentissage. Toutes les métriques sont agrégées par épisode : les récompenses cumulatives, la longueur des épisodes conditionnellement au succès, les taux de succès et de chute, et le risque cumulatif d'une trajectoire. Le risque cumulatif d'une trajectoire $\tau_i = (s_0, \ldots, s_{T_i})$ de longueur T_i est défini comme $\Delta_i = 2\sum_{t=0}^{T_i} \delta(s_t)$, où $\delta(s_t)$ est une fonction retournant le niveau de risque de l'état s_t, c'est-à-dire le nombre de trous adjacents à la cellule courante. Nous multiplions ce risque par 2 afin d'obtenir une métrique similaire à celle de Zhu et al. [2025], à la différence que nous considérons également le risque associé aux cellules ayant trois trous adjacents (Fig. 1). Cette métrique pénalise fortement les trajectoires non sécuritaires passant par une ou plusieurs cellules à risque.

Lors de l'entraînement, chaque métrique est lissée en calculant une moyenne sur une fenêtre de 100 épisodes, puis en estimant la moyenne et l'écart-type sur les dix répétitions. La performance des politiques apprises suite à l'entraînement est évaluée en générant 100 trajectoires à partir d'une politique *greedy* (déterministe) pour chacune des dix répétitions.

4 Résultats

Les résultats des métriques en entraînement et en évaluation sont présentés respectivement à la Figure 2 et au Tableau 1. Les meilleurs hyperparamètres pour P3O, maximisant le taux de succès et minimisant le taux de chute, sont $\kappa = 0.75$ (8×8), $\kappa = 0.5$ (10×10) et $\kappa = 1$, $\alpha = 0.05$ (16×16) (Annexe A, Fig. 3). Sur l'environnement 8×8, les trois stratégies convergent rapidement vers des récompenses similaires (Fig. 2), mais PPO emprunte des trajectoires plus risquées, se traduisant par un taux de chute légèrement supérieur. PPO et P3O explorent davantage la région plus risquée du centre de la grille, car les actions optimales y sont orientées de manière plus cohérente que celles de Q-learning (Annexe A, Fig. 4, 5, 6). P3O est la seule stratégie à respecter le seuil de 0.0975 en moyenne lors de l'évaluation (Tableau 1), bien

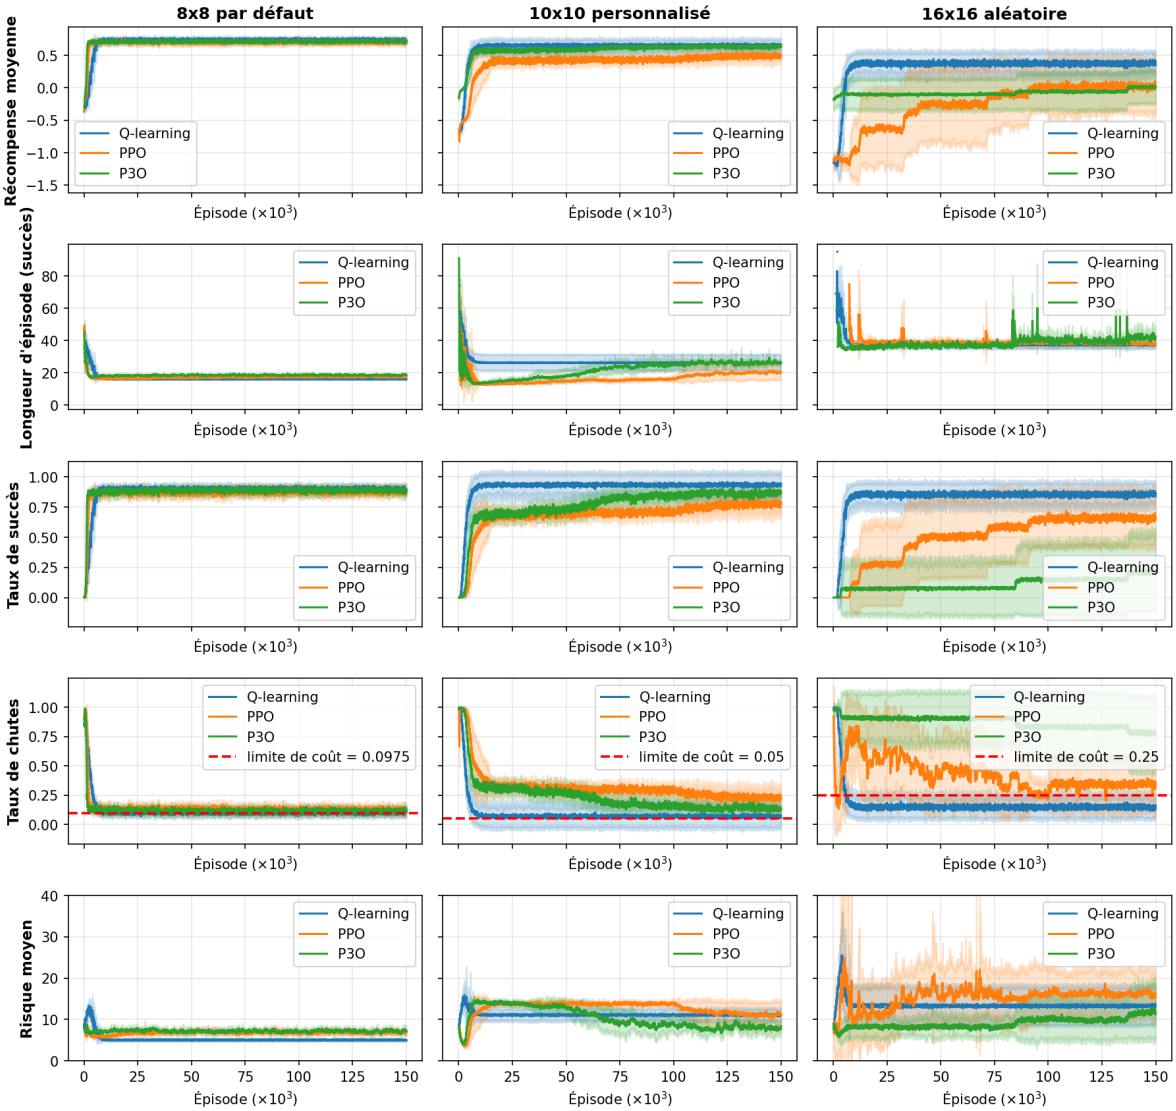


Figure 2: Métriques d'entraînement (± écart-type) pour les différentes stratégies RL et environnements.

que son risque moyen pendant l'apprentissage reste supérieur à celui de Q-learning. L'application d'un coefficient de 0.5 à la perte du critique de coût afin d'aligner sa vitesse d'apprentissage sur celle du critique de récompense dégrade les performances de P3O (Annexe A, Fig. 3).

Sur l'environnement 10×10 personnalisé, les écarts se creusent : Q-learning atteint une récompense moyenne plus élevée et un taux de chute plus faible durant l'entraînement, au prix de trajectoires (avec succès) plus longues, tandis que PPO emprunte des chemins plus courts mais plus risqués (Fig. 2). Néanmoins, PPO parvient à réduire progressivement son risque moyen. P3O améliore les performances de PPO, mais Q-learning demeure le plus performant, avec un taux de chute proche du seuil de 0.05, malgré l'absence de contrainte explicite (Fig. 2, Tableau 1). La politique apprise par Q-learning présente davantage de changements de direction, tandis que celles de PPO et P3O apparaissent plus cohérentes sur l'ensemble de la grille (Annexe A, Fig. 7, 8, 9). Ces résultats suggèrent une exploration plus large de l'espace d'états pour PPO et P3O, mais un apprentissage plus lent que Q-learning. Des ajustements du taux d'apprentissage n'ont pas amélioré la convergence de PPO par rapport à la valeur par défaut (0.003) (Annexe A, Fig. 13).

Dans les environnements 16×16, la divergence est nette : Q-learning obtient une récompense positive et un taux de chute inférieur au seuil fixé pour P3O (CMDP), tandis que PPO converge lentement, avec des performances moindres (Fig. 2). À la fin de l'entraînement, 9 agents PPO sur 10 ont connu des succès. Pour P3O, malgré nos efforts de recherche d'hyperparamètres, seulement 3 agents sur 10 ont connu des succès. Plusieurs agents P3O adoptent une stratégie

Table 1: Métriques d'évaluation (± écart-type) regroupées par cas d'étude.

Cas	Algorithme	Récompense moyenne	Longueur d'épisode (succès)	Taux de succès	Taux de chute	Risque moyen
8x8	Q-learning	0.73 ± 0.04	15.95 ± 0.10	0.89 ± 0.04	0.109 ± 0.039	5.10 ± 0.25
	PPO	0.71 ± 0.09	17.40 ± 4.92	0.89 ± 0.04	0.103 ± 0.025	5.17 ± 0.66
	P3O	0.76 ± 0.02	15.93 ± 0.24	0.90 ± 0.02	0.096 ± 0.025	5.72 ± 1.21
10×10	Q-learning	0.66 ± 0.09	25.93 ± 5.26	0.93 ± 0.10	0.067 ± 0.095	11.04 ± 1.73
	PPO	0.51 ± 0.10	19.74 ± 5.02	0.78 ± 0.10	0.217 ± 0.097	9.61 ± 4.51
	P3O	0.62 ± 0.08	27.73 ± 9.52	0.87 ± 0.05	0.126 ± 0.053	6.42 ± 2.40
16×16	Q-learning	0.40 ± 0.18	37.02 ± 2.33	0.87 ± 0.10	0.134 ± 0.100	13.21 ± 4.75
	PPO	0.09 ± 0.49	41.03 ± 11.76	0.70 ± 0.27	0.283 ± 0.266	19.15 ± 11.27
	P3O	-0.22 ± 0.60	39.88 ± 11.21	0.24 ± 0.38	0.462 ± 0.417	24.46 ± 25.23

dégénérée, privilégiant des chutes rapides ou des trajectoires qui tournent en rond, plutôt que de tenter d'atteindre l'objectif (Annexe A, Fig. 12). L'ajout d'une composante d'entropie dans la perte ($\alpha = 0.05$) semble améliorer les performances (Annexe A, Fig. 3), mais une recherche d'hyperparamètres plus approfondie demeure nécessaire.

5 Discussion

L'environnement 8×8 permet de comparer nos résultats à la littérature : les trois stratégies atteignent des niveaux de risque moyen similaires à ceux rapportés par Zhu et al. [2025], fondés sur des préférences humaines et du Q-learning. Contrairement à notre hypothèse de départ, le Q-learning surpasse nettement PPO et P3O sur les environnements 10×10 et 16×16. Cela s'explique probablement par une exploration plus intensive et une convergence plus lente de PPO et P3O liée au mécanisme de *clipping*, ainsi que par des épisodes plus longs que dans des approches *off-policy* comme DQN [Fuente and Guerra, 2024]. Cependant, une exploration plus large peut s'avérer avantageuse dans des environnements CMDP plus complexes, car l'ajout de contraintes réduit l'espace d'actions admissibles et rend la maximisation du retour plus difficile. En effet, l'augmentation de l'exploration, via l'ajout d'un facteur d'entropie à la politique, a légèrement amélioré les performances de P3O dans l'environnement 16×16. Par ailleurs, bien que l'approximation de fonction utilisée pour PPO et P3O ne soit pas nécessaire dans notre cas, elle pourrait devenir bénéfique dans des environnements plus vastes ou structurés spatialement. Par exemple, les états pourraient être représentés par leurs positions (x, y) sur la grille plutôt que par des indices discrets.

Sauf pour l'environnement 8x8, la stratégie P3O ne parvient pas à respecter le seuil fixé dans le CMDP. Ce type de stratégie nécessite un facteur de pénalité (κ) suffisamment grand pour garantir une équivalence avec le problème primal du CMDP. Toutefois, augmenter κ accroît l'erreur d'approximation [Dai et al., 2023]. Contrairement à Zhang et al. [2022], nous observons de grandes différences de performances pour différentes valeurs de κ. La valeur de κ dans P3O doit donc être soigneusement calibrée : trop faible, elle ne pénalise pas suffisamment les violations de contrainte ; trop élevée, elle peut déstabiliser l'apprentissage et conduire à des stratégies dégénérées. Des méthodes plus récentes, comme APPO [Dai et al., 2023], reformulent le terme de pénalité afin que la solution soit exactement la même que celle du problème primal. Néanmoins, P3O peut demeurer une approche simple et efficace en échantillons [Zhang et al., 2022], avec des temps d'exécution par pas de temps similaires à ceux de PPO (Q-learning : 1 ms, PPO : 15 ms, P3O : 19 ms). Notre implémentation de P3O n'utilise pas de clipping pour la perte de coût, mais cela devrait être envisagé afin d'éviter que la nouvelle politique ne sorte de la région de confiance lors des réductions de pénalité [Zhang et al., 2022].

Dans notre étude, l'ajout d'une récompense négative pour une chute dans le MDP (p. ex. -0.5), par rapport à une récompense nulle et un coût de 1 dans le CMDP, conduit à des processus de décision markoviens différents. Le choix d'une pénalité dans le MDP est délicat pour garantir l'apprentissage d'une politique sécuritaire, ce qui fait du CMDP la formulation privilégiée pour ce type de problème [Ray et al., 2019]. Par exemple, avec une récompense de -1 pour une chute, PPO (MDP) obtient des performances inférieures à P3O (CMDP) avec un coût de 1 (récompense nulle), confirmant que ces formulations ne sont pas équivalentes (Annexe A, Fig. 14).

En conclusion, bien que le Q-learning (MDP) se soit révélé le plus performant dans les trois cas d'études, la formulation CMDP demeure préférable pour modéliser des problèmes d'optimisation sous contraintes alignés sur les besoins de l'utilisateur. Nos résultats mettent en évidence les limites des approches à base de pénalité comme P3O pour satisfaire des contraintes strictes, car elles sont conçues pour s'approcher du respect des contraintes en moyenne. Une recherche d'hyperparamètres plus approfondie pour P3O, ainsi que l'exploration d'autres méthodes, p. ex., une approche sécuritaire *off-policy*, pourrait améliorer les performances. Pour des environnements exigeants nécessitant le respect strict des contraintes, nous suggérons d'explorer des approches à garanties formelles telles que PPO-Shield.

References

Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, et al. Gymnasium: A standard interface for reinforcement learning environments. *arXiv preprint*, arXiv:2407.17032, 2024.

Hao Zhu, Jialin Wang, and Rui Gao. Eeg-based inverse reinforcement learning for safety-oriented global path planning in dynamic environments. *Applied Sciences*, 15(11), 2025.

Alex Ray, Joshua Achiam, and Dario Amodei. Benchmarking safe exploration in deep reinforcement learning. *arXiv preprint*, arXiv:1910.01708, 2019.

Christopher John Cornish Hellaby Watkins. *Learning from Delayed Rewards*. PhD thesis, King's College, University of Cambridge, Cambridge, UK, May 1989.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint*, arXiv:1707.06347, 2017.

Neil De La Fuente and Daniel A. Vidal Guerra. A comparative study of deep reinforcement learning models: DQN vs PPO vs A2C. *arXiv preprint*, arXiv:2407.14151, 2024.

Ryan Sullivan, J. K. Terry, Benjamin Black, and John P. Dickerson. Cliff diving: Exploring reward surfaces in reinforcement learning environments. In Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvári, Gang Niu, and Sivan Sabato, editors, *International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, MD, USA*, Proceedings of Machine Learning Research, pages 20744–20776. PMLR, 2022.

Lindsay Spoor, Álvaro Serra-Gómez, Aske Plaat, and Thomas M. Moerland. An empirical study of lagrangian methods in safe reinforcement learning. *arXiv preprint*, arXiv:2510.17564, 2025.

Adam Stooke, Joshua Achiam, and Pieter Abbeel. Responsive safety in reinforcement learning by PID lagrangian methods. In *Proceedings of the 37th International Conference on Machine Learning, ICML 2020, 13-18 July 2020, Virtual Event*, Proceedings of Machine Learning Research, pages 9133–9143. PMLR, 2020.

Linrui Zhang, Li Shen, Long Yang, Shixiang Chen, Xueqian Wang, Bo Yuan, and Dacheng Tao. Penalized proximal policy optimization for safe reinforcement learning. In Luc De Raedt, editor, *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI 2022, 23-29 July 2022, Vienna, Austria*, pages 3744–3750. ijcai.org, 2022.

Edwin Hamel-De le Court, Francesco Belardinelli, and Alexander W. Goodall. Probabilistic shielding for safe reinforcement learning. In Toby Walsh, Julie Shah, and Zico Kolter, editors, *Thirty-Ninth AAAI Conference on Artificial Intelligence, AAAI 2025, February 25 - March 4, 2025, Philadelphia, PA, USA*, pages 16091–16099. AAAI Press, 2025.

Juntao Dai, Jiaming Ji, Long Yang, Qian Zheng, and Gang Pan. Augmented proximal policy optimization for safe reinforcement learning. In Brian Williams, Yiling Chen, and Jennifer Neville, editors, *Thirty-Seventh AAAI Conference on Artificial Intelligence, AAAI 2023, Washington, DC, USA, February 7-14, 2023*, pages 7288–7295. AAAI Press, 2023.

Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.

Jiaming Ji, Jiayi Zhou, Borong Zhang, Juntao Dai, Xuehai Pan, Ruiyang Sun, Weidong Huang, Yiran Geng, Mickel Liu, and Yaodong Yang. Omnisafe: An infrastructure for accelerating safe reinforcement learning research. *Journal of Machine Learning Research*, 25(285):1–6, 2024.

John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In Yoshua Bengio and Yann LeCun, editors, *4th International Conference on Learning Representations, ICLR 2016, May 2-4, 2016, San Juan, Puerto Rico, Conference Track Proceedings*, 2016.

A Figures supplémentaires

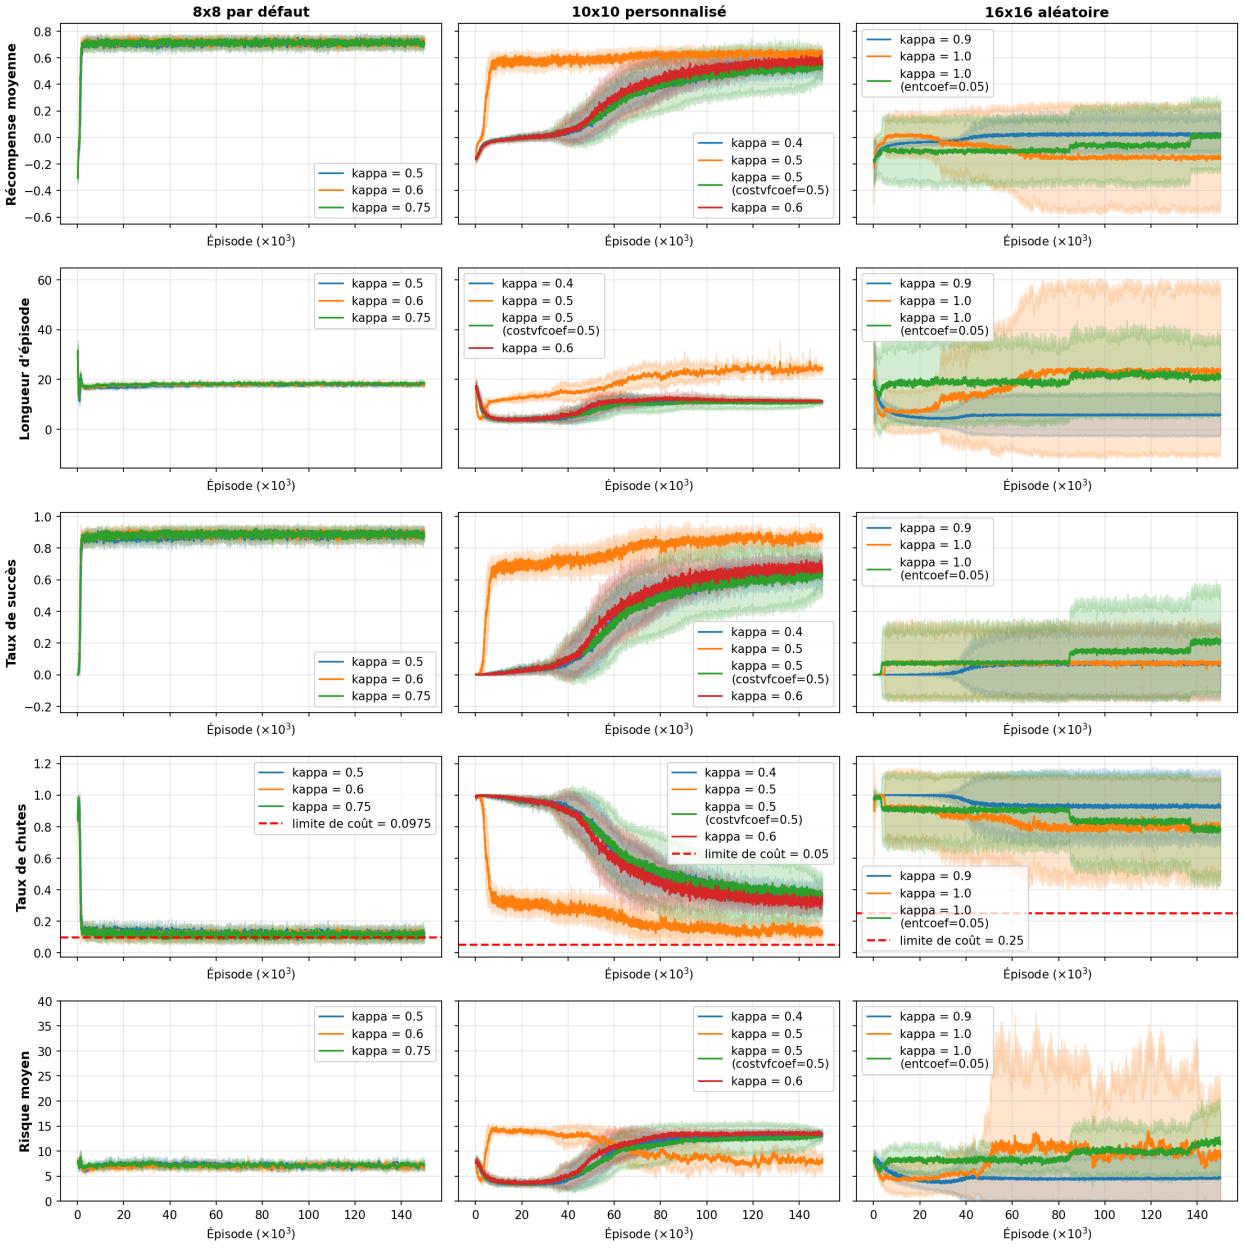


Figure 3: Métriques d'entraînement ($\pm$ écart-type) pour la recherche d'hyperparamètres de la stratégie P3O. Les hyperparamètres testés sont kappa: modification de la valeur de κ pondérant la perte de coût pour l'acteur ($\mathcal{L}_C$) dans la perte P3O. Costvfcoef: application d'un coefficient à la perte du critique de coût. Entcoef : coefficient α pondérant le terme de régularisation d'entropie ($\mathcal{L}_{\text{entropy}}$) dans la perte P3O. Lorsque non spécifié, les valeurs par défaut de costvfcoef=1 et entcoef=0 sont utilisées. Ici, nous choisissons de montrer la longueur des épisodes, plutôt que la longueur des épisodes conditionnellement au succès afin de mieux représenter la dynamique d'apprentissage.

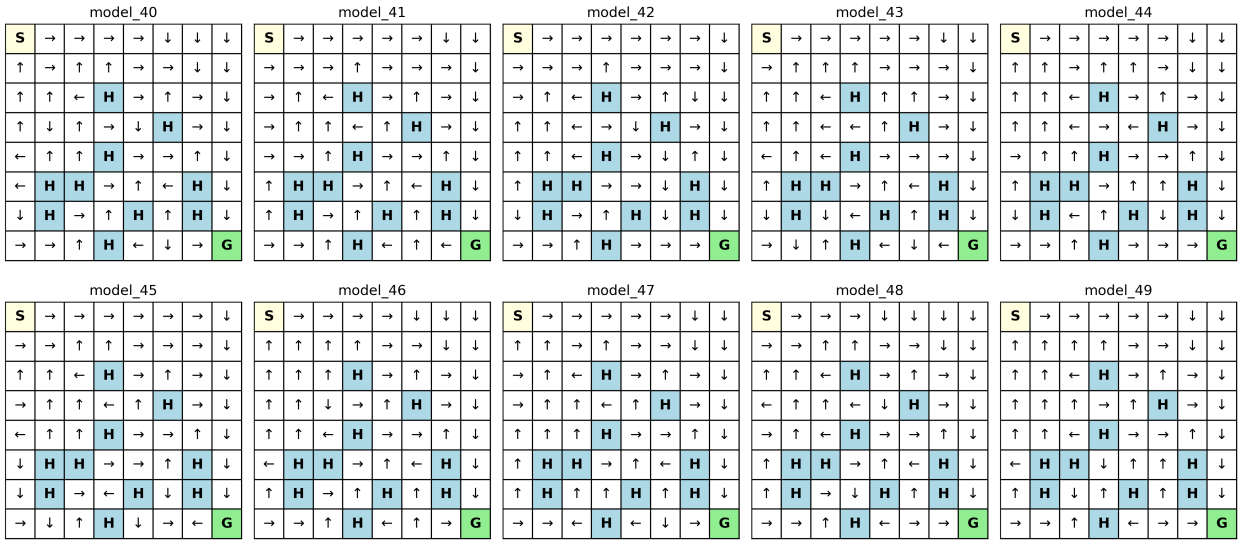


Figure 4: Politiques apprises par Q-learning sur l'environnement 8x8 pour chacune des 10 répétitions. L'action de valeur maximale est représentée pour chacun des états. S = état de départ; G = but; H = trou.

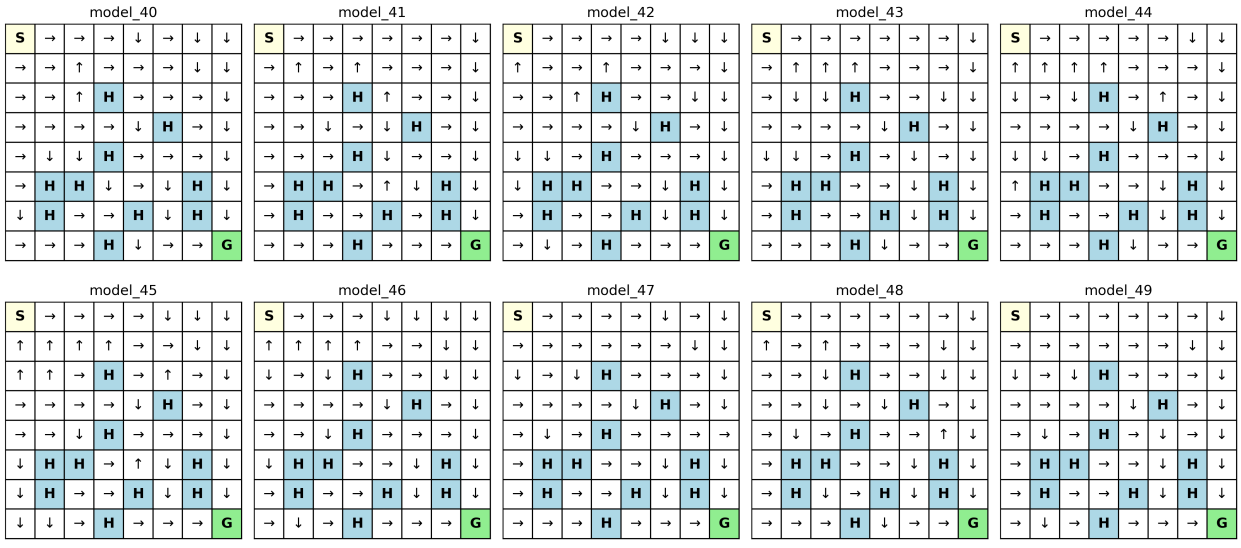


Figure 5: Politiques apprises par PPO sur l'environnement 8x8 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

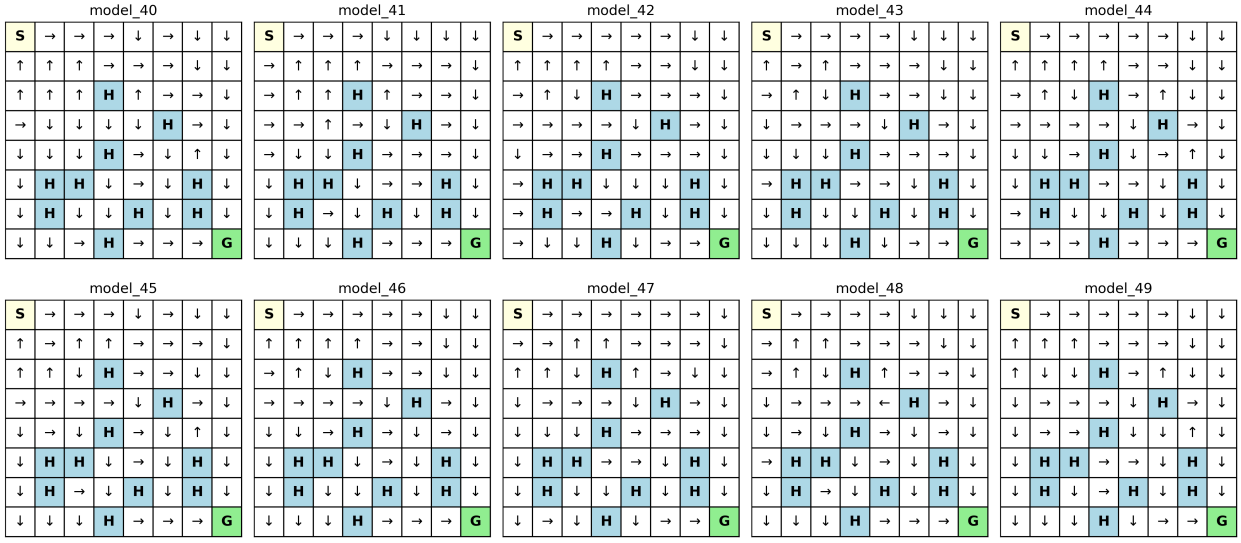


Figure 6: Politiques apprises par P3O sur l'environnement 8x8 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

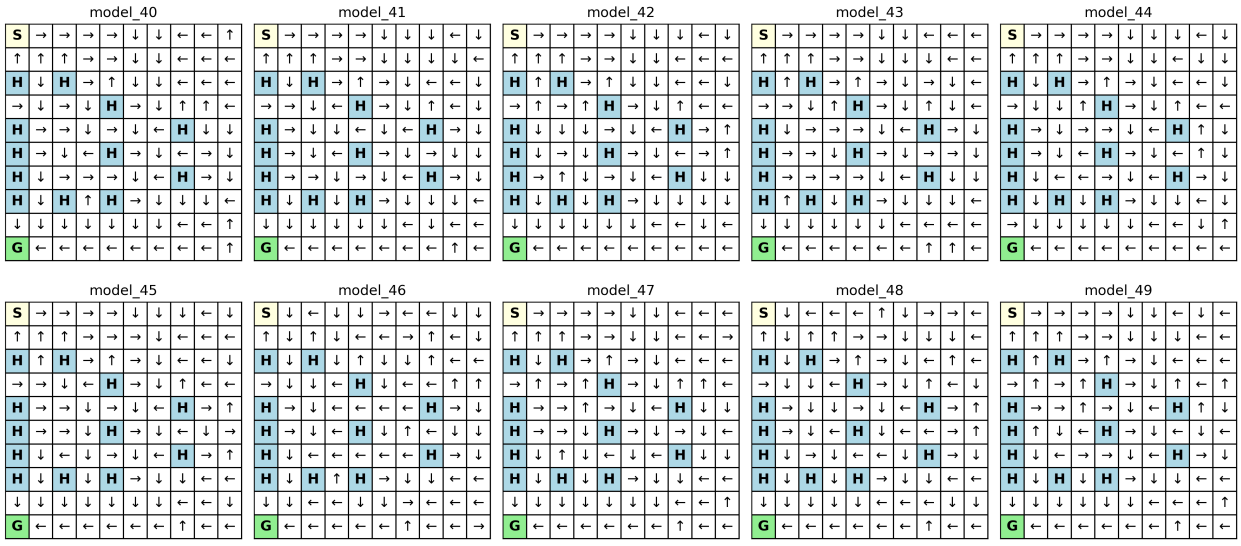


Figure 7: Politiques apprises par Q-learning sur l'environnement 10x10 pour chacune des 10 répétitions. L'action de valeur maximale est représentée pour chacun des états. S = état de départ; G = but; H = trou.

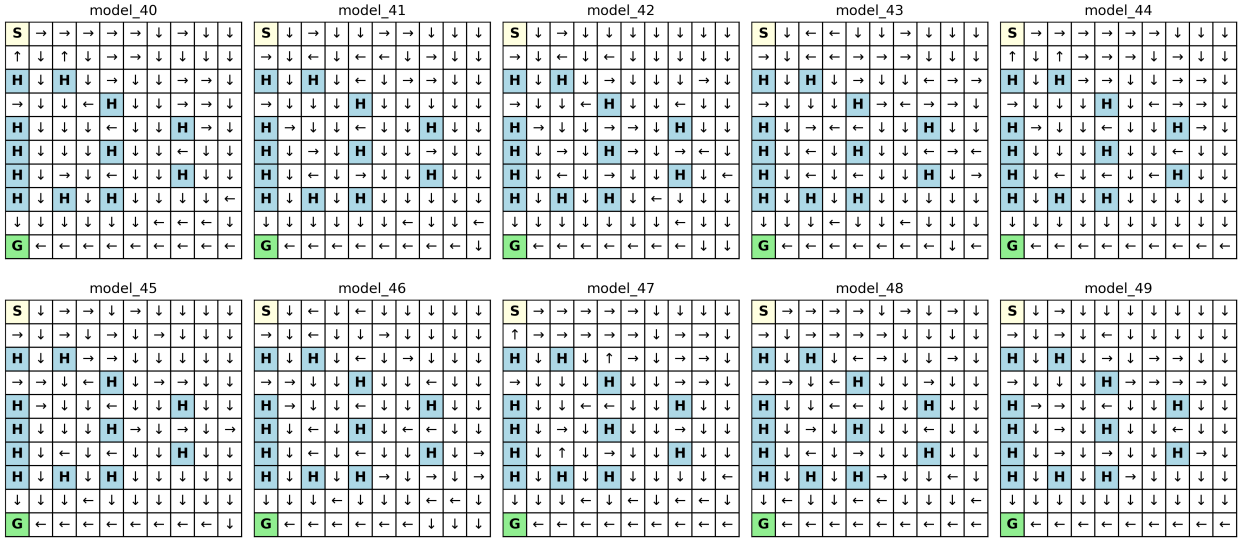


Figure 8: Politiques apprises par PPO sur l'environnement 10x10 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

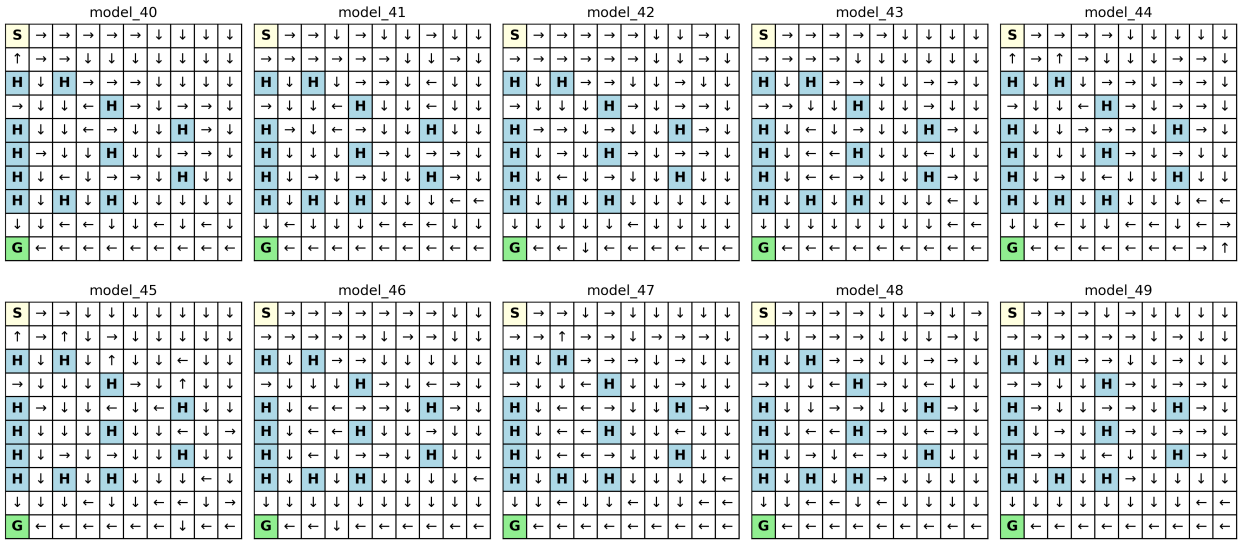


Figure 9: Politiques apprises par P3O sur l'environnement 10x10 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

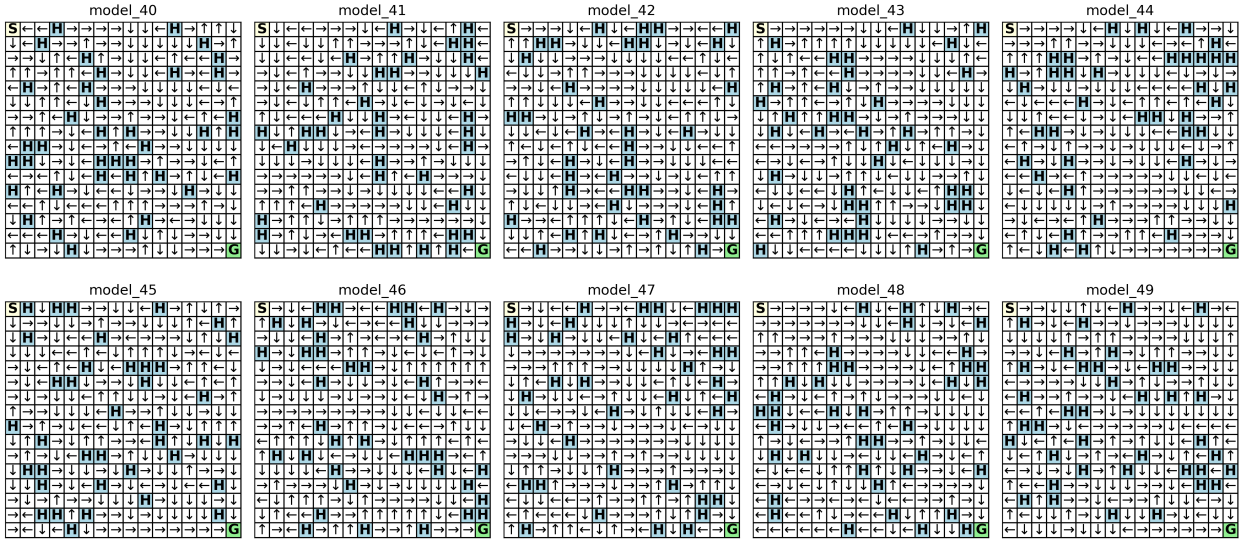


Figure 10: Politiques apprises par Q-learning sur l'environnement 16x16 pour chacune des 10 répétitions. L'action de valeur maximale est représentée pour chacun des états. S = état de départ; G = but; H = trou.

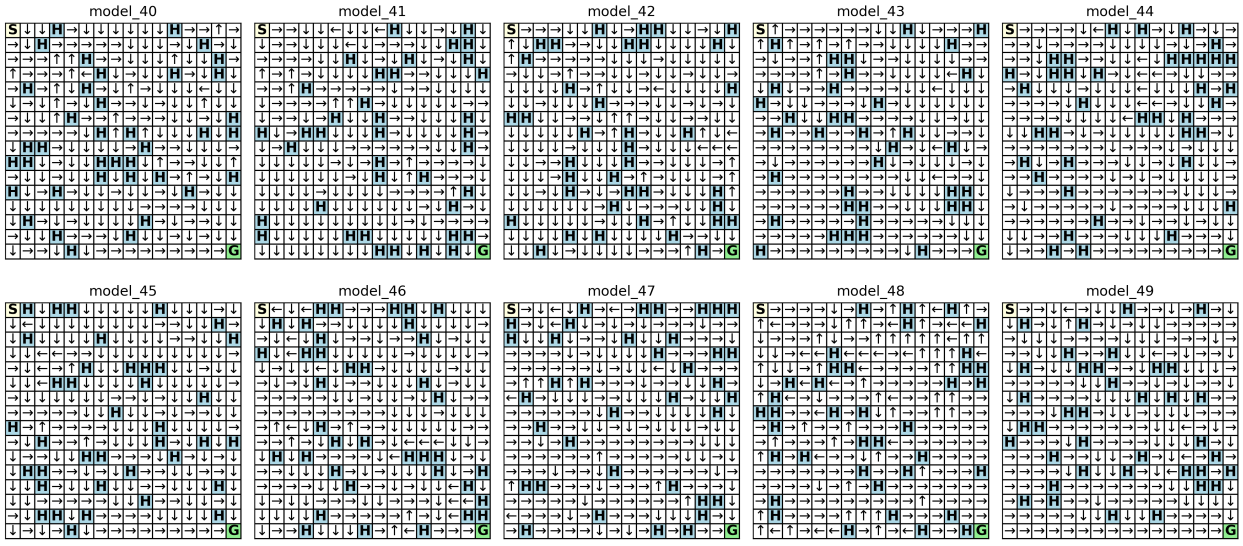


Figure 11: Politiques apprises par PPO sur l'environnement 16x16 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

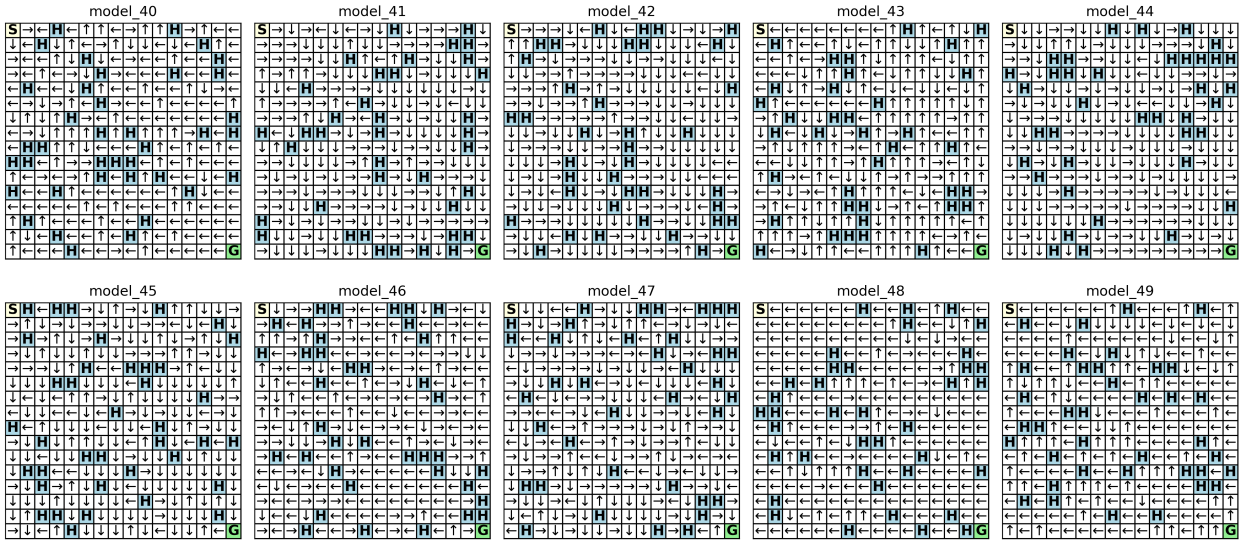


Figure 12: Politiques apprises par P3O sur l'environnement 16x16 pour chacune des 10 répétitions. L'action ayant la probabilité maximale d'être choisie est représentée pour chacun des états. S = état de départ; G = but; H = trou.

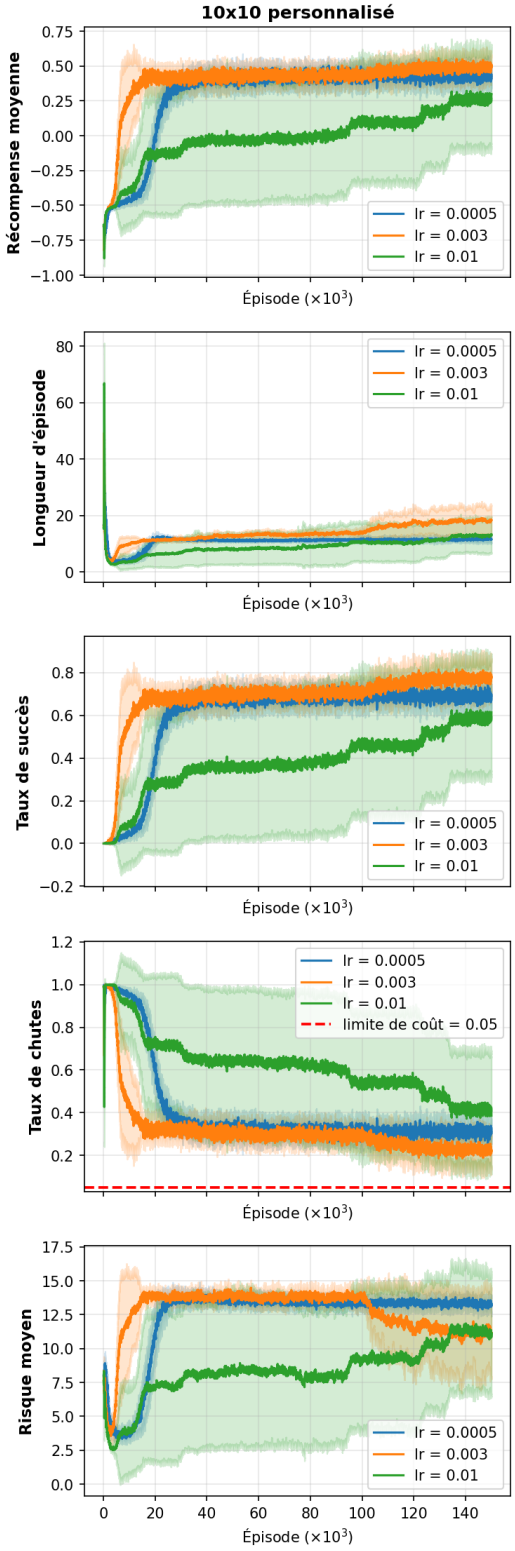


Figure 13: Métriques d'entraînement (± écart-type) pour différents taux d'apprentissages (lr) de la stratégie PPO dans l'environnement 10x10. Ici, nous choisissons de montrer la longueur des épisodes, plutôt que la longueur des épisodes conditionnellement au succès afin de mieux représenter la dynamique d'apprentissage.

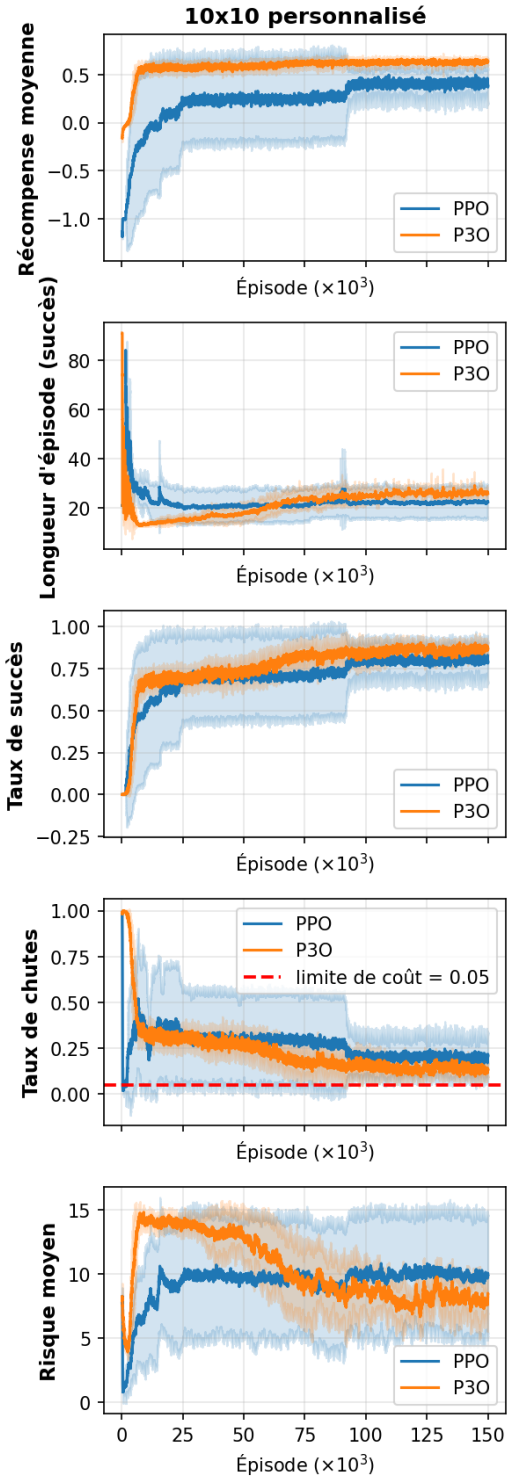


Figure 14: Comparaison des métriques d'entraînement ($\pm$ écart-type) pour la stratégie PPO (MDP) avec récompense de $R_H = -1$ lors d'une chute versus la stratégie P3O (CMDP) avec une récompense de $R_H = 0$ et un coût $C_H = 1$ pour une chute. Les autres récompenses sont les mêmes que celles définies dans la section *Cas d'étude*.